

Rapport pour le comité d'accompagnement, troisième année de thèse

Guyliann Engels

03-12-2020

Avancement de la recherche

Titre provisoire de la thèse:

...

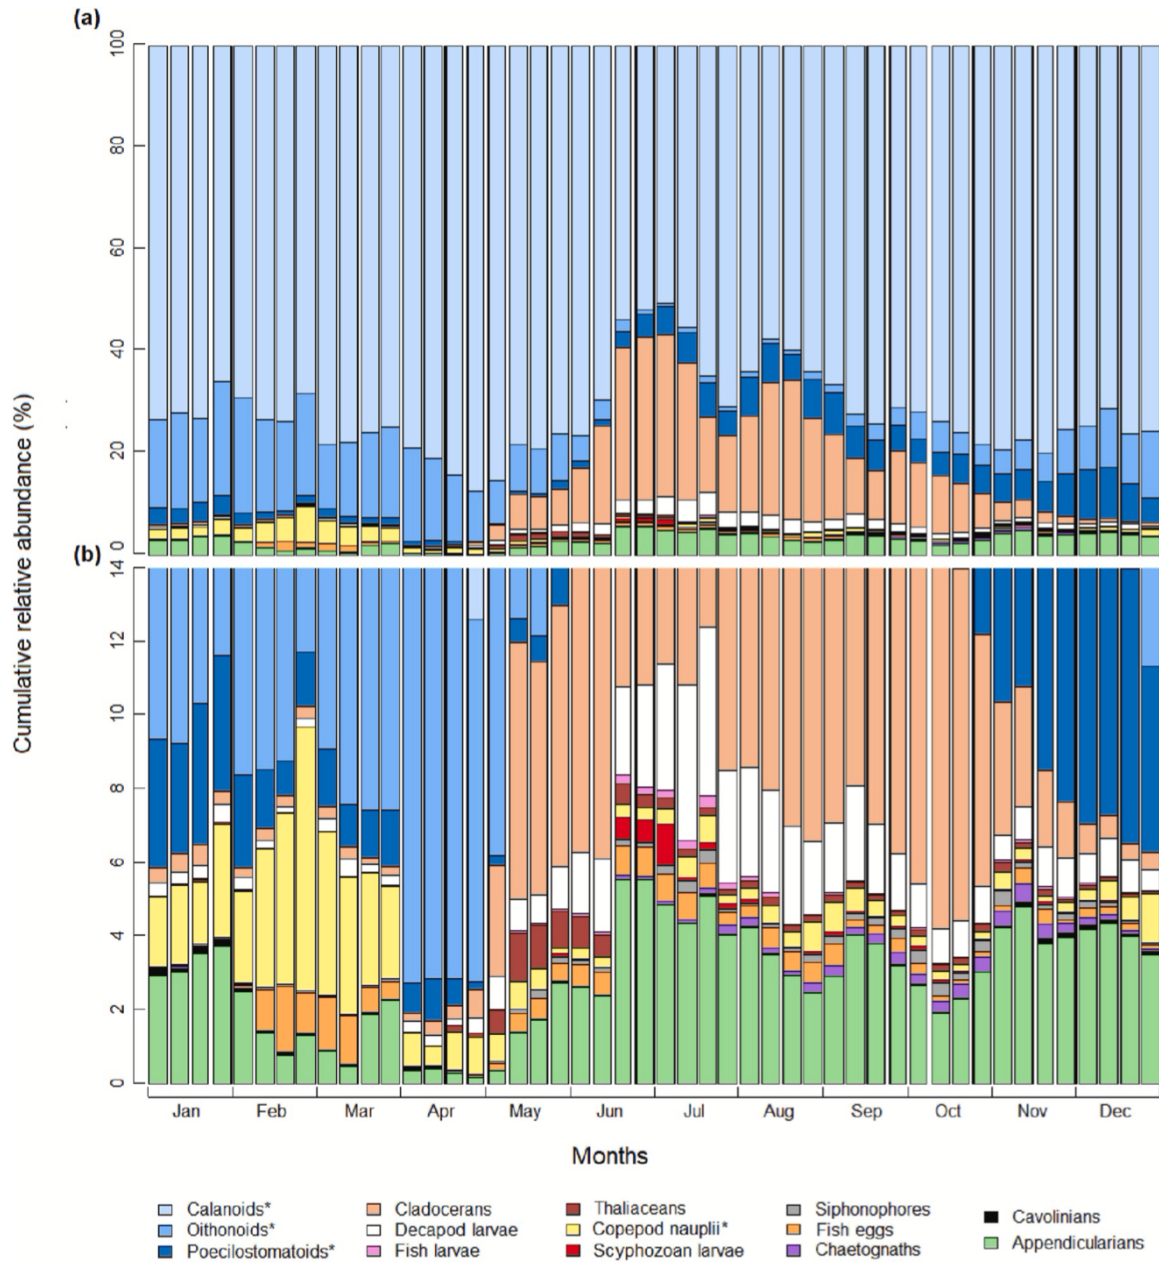
Résumé :

Le plancton est un élément majeur des écosystèmes marins. Des études proposent d'utiliser le plancton comme indicateur de l'état de la qualité de l'eau ... De ce fait le suivi de la dynamique du plancton est un enjeu capital.

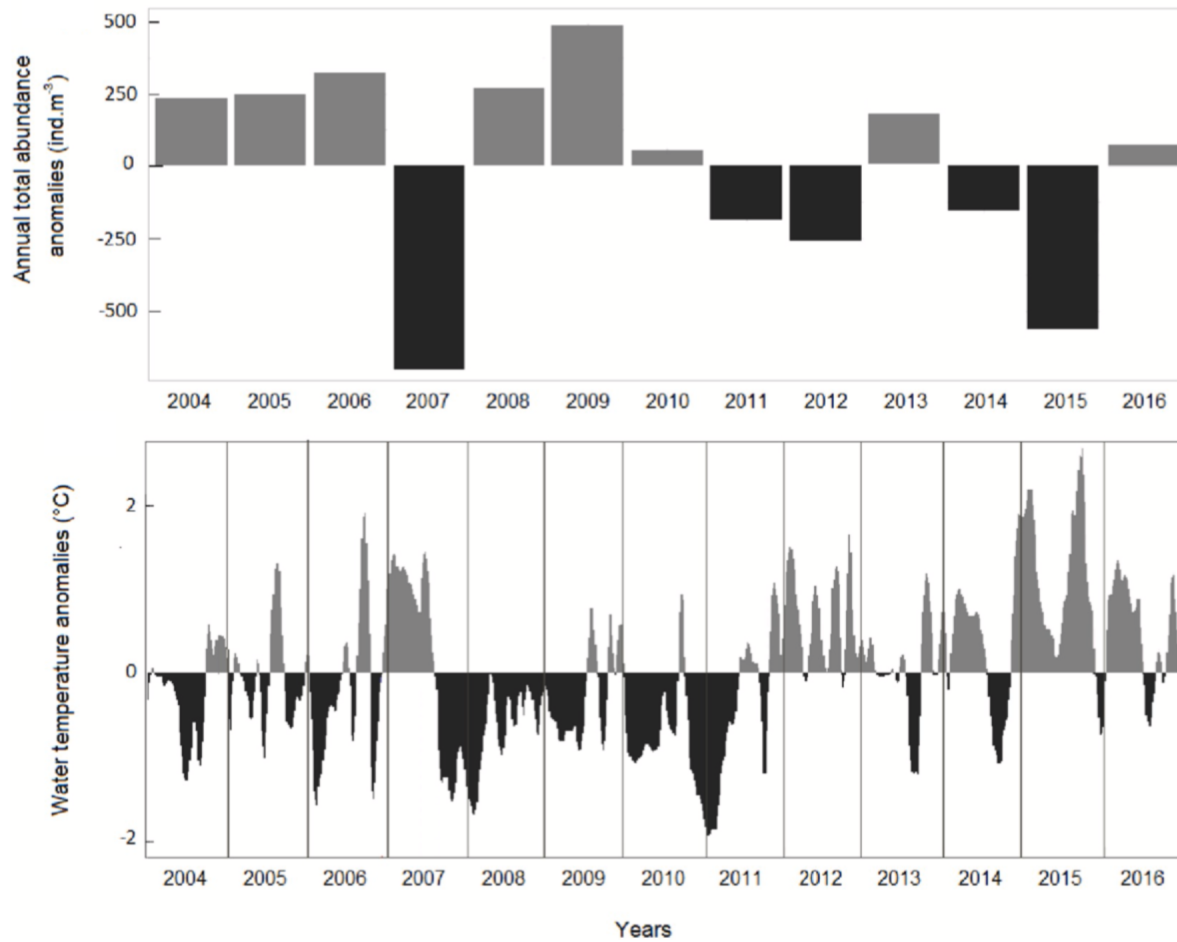
L'étape limitante actuelle dans ce suivi et l'analyse des échantillons prélevés. La classification automatique du plancton sur base d'image a permis de gagner en vitesse par rapport à une classification manuelle. Cependant de nombreuses questions restent en suspens sur la qualité de la classification.

Chapitre 1 : Suivi de la dynamique zooplanctonique en subsurface au cours du temps en baie de Calvi Corse

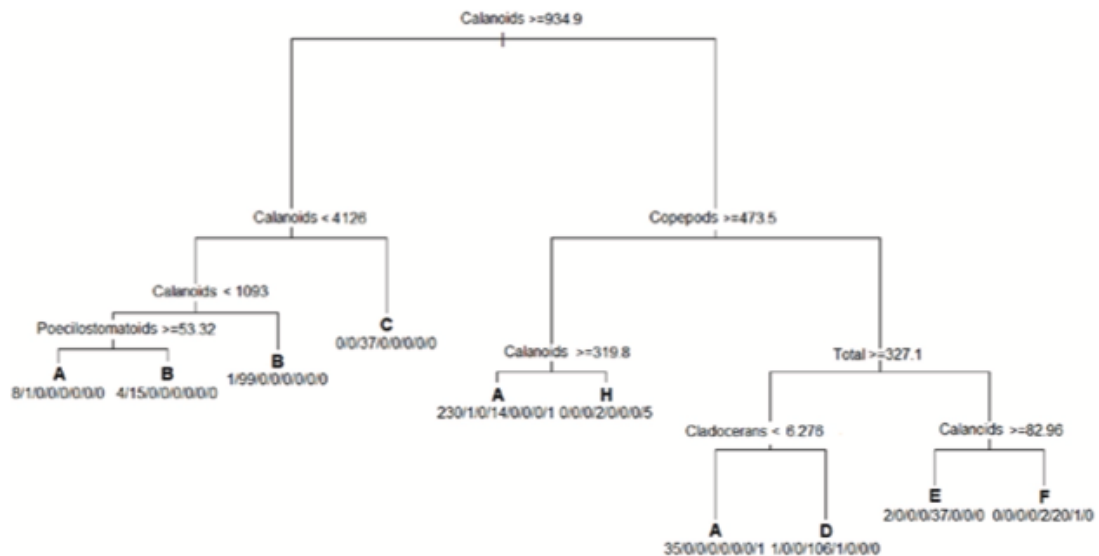
La communauté mésozooplanctonique est répartie en 14 groupes pour cette étude. L'étude s'intéresse à la description de la communauté entre 2004 et 2016. Les copépodes représentent la plus grande fraction des individus échantillonnés.




Les anomalies de température de l'eau et les anomalies d'abondance totales des individus sont corrélées. De fortes températures réduisent l'abondance du plancton. Les années 2007, 2012 et 2015 sont des années particulières.



L'originalité de cette étude est la définition de 8 stades qui permettent de résumer l'état global de la communauté planctonique. Ces stades sont obtenus par classification hiérarchique ascendante (CAH). Les règles qui définissent chaque stade sont ensuite obtenues par arbre de partitionnement.



Le nombre d'occurrence maximale des stades permet de définir un profil annuel type.



Ce profil met en avant un changement particulier de la communauté en mars avec le pic de copépode suivi par un second changement de la communauté en juin avec le pic des cladocères.

Avancement : L'article de ce premier chapitre est publié (Fullgrabe et al. 2020). Ce premier chapitre est donc terminé

Chapitre 2 : Comparaison entre les organismes planctoniques de subsurface et de profondeur en baie de Calvi Corse.

La méthode d'échantillonnage la plus utilisée est le trait de filet. Cette méthode est peu couteuse et simple de mise en œuvre. Elle permet d'avoir une estimation de l'abondance planctonique.

On recense principalement 3 types de traits : les traits verticaux, les traits horizontaux et les traits obliques. Les traits verticaux sont les traits les plus utilisés car ils permettent d'intégrer la totalité de la colonne d'eau.

La station de recherche de Calvi réalise des prélèvements via des traits de plancton horizontaux depuis 2003. Ils ont par la suite débuté des prélèvements verticaux depuis 2012.

30 échantillons ont été sélectionnée afin de réaliser cette comparaison.

Ce chapitre a pour objectif de permettre la comparaison avec les autres séries temporelles menées sur le plancton en Méditerranée (ajouter le nombre de série en cours ...) dont l'échantillonnage est obtenu par traits verticaux.


Avancement : Deux mémoires ont été réalisé sur la comparaison de la communauté planctonique obtenue lors de traits de plancton horizontaux versus la communauté planctonique obtenue lors de traits de plancton verticaux. La compilation des données finales sont en cours de réalisation pour la rédaction d'une publication.

Chapitre 3 : Correction des erreurs du à la classification automatique via la validation de suspects.

La classification automatique est très employée actuellement afin de classer rapidement des images de plancton. La classification se base sur un training set et d'algorithme qui vont utiliser ce set d'apprentissage afin de classer les items inconnues. Cette méthode seule comprend encore trop d'erreurs.

Différents outils ont été proposé afin d'améliorer la classification prédite par les algorithmes sur base du training set. La méthode la plus simple mais la plus longue est de réaliser une validation manuelle de chaque items. La classification automatique est employé comme un outil qui propose une classe uniquement. Elle requiert néanmoins d'avoir une expert en taxonomie qui valide en permanence les échantillons de plancton.


Une méthode de validation plus rapide est de déterminer des items suspects et de valider principalement ces items. Le schéma ci-dessous propose un schéma de la méthode.



On définit la composition d'un échantillon prélevé sur base d'outils de classifications automatiques. Les items peuvent être classés en items suspects ou en items de confiance (lors de la première détection, tous les items sont des suspects). Parmi ces items, une proportion de maximum 5% des images de l'échantillon sont à valider. Il y aura une faible proportion d'items aléatoires, une large proportion d'items suspects et une faible proportion d'items de confiances. Sur base des validations manuelles de nouvelles matrices de confusion sont calculées.

Ce processus est itératif. Les éléments validés sont employés pour améliorer la classification et la détection de nouveaux suspects à valider. Cette méthode permet donc de s'attarder principalement sur les items suspects d'un échantillon.

En partant du principe que la validation ne comprend aucune erreur, la validation manuelle classique va permettre de corriger les erreurs. Lorsque 100% de l'échantillon est validé, l'erreur tombe à 0%.



L'axe Y montre la dissimilarité entre les abondances prédites de chaque classe au sein de l'échantillon et les abondances réelles (obtenue en classant manuellement chaque items). L'axe X indique le pourcentage d'items validés manuellement.

La ligne en pointillé grisée indique la diminution linéaire du la dissimilarité lors de la validation manuelle de chaque item. Il faut dépasser 80% afin de tomber sous les 5% de dissimilarité.

Avancement :

Une publication est en cours d'écriture sur *Error correction of automatic classification of plankton digital images through partial validation of suspect items in Zoo/PhytoImage*.

Des tests vont débuter sur la correction d'erreur sur des échantillons de zooplancton de la baie de calvi afin de compléter les résultats obtenus sur le phytoplancton.

Chapitre 4 : ...

Ce chapitre est à l'état de réflexion.

Lors du lancement d'une nouvelle étude qui nécessite la classification automatique d'organismes planctoniques, il faut réaliser un set d'apprentissage le plus rapidement possible afin de pouvoir débiter l'étude. On utilise principalement deux méthodes pour classer des images de planctons.

La première méthode consiste à classer quelques images dans les différents groupes de notre set d'apprentissage. Une série d'attributs vont être calculés sur chaque image. Sur base du tableau des attributs et de la classe de chaque image, des algorithmes comme le Random Forest sont employés pour réaliser la classification de nouvelles images.

Une seconde méthode consiste à classer un très grand nombre d'images dans chaque catégorie et d'utiliser des outils de deep learning comme CNN (convolutional Neural Networks).

Lors du lancement d'une étude, il n'est pas possible d'avoir un set d'apprentissage assez conséquent que pour employer le deep learning. Il existe des méthodes comme le transfer learning afin de pouvoir utiliser un set d'apprentissage plus restreint. Des algorithmes comme le RF sont déjà efficaces lorsque l'on a une 100 images par groupe.

Ce chapitre s'intéresse donc à la réflexion d'un protocole associant, une classification manuelle au début, suivi de classification automatique avec un RF associé aux outils de correction d'erreurs (chapitre 3) afin de valider les images.

Ce chapitre souhaite s'intéresser à comparer les deux approches et de mettre en avant à partir de quelle taille un set d'apprentissage est suffisant que pour que la seconde méthode soit plus efficace.

Données disponibles

Les données suivantes sont disponibles et vont être employées dans le cadre de cette étude

- Série temporelle de Calvi ce qui représente environs 9000000 images
 - 335 échantillons entre 2004 et 2016
 - 76 échantillons entre 2012 et 2016
- Série Belspo ...
- IFREMER/REPHIS : un set d'apprentissage de 3787 images d'organisme phytoplanctoniques (principalement)
- Open Data
 - ZooScanNet: plankton images captured with the ZooScan comprend 1433278 images collectée entre 2007 et 2017
 - Kaggle challenge : National Data Science Bowl Predict ocean health, one plankton at a time avec 50000000 images

Activités valorisables pour la formation doctorale

L'ensemble des publications et communications scientifiques sont regroupés dans le fichier `publication_di_20201023.pdf`.

Activités supplémentaires valorisables pour la formation doctorale

- 2020
 - 2h de séminaire : RBZS Workshop *Stress Management - keeping sane during your PhD* (8 décembre)
 - 2h de séminaire : RBZS Workshop *Present your Research with Impact* (1 décembre)
 - 4h (temps estimé) de formation sur OpenClassrooms : *Adoptez les API REST pour vos projets web*
 - 8h (temps estimé) de formation sur OpenClassrooms : *Réalisez des rapports statistiques clairs et impactants*

- 8h (temps estimé) de formation sur OpenClassrooms : *Testez vos idées avec le lean prototyping*
- 12h (temps estimé) de formation sur OpenClassrooms : *Initiez-vous à Python pour l'analyse de données*
- 20h (temps estimé) de formation sur OpenClassrooms : *Initiez-vous à l'algèbre relationnelle avec le langage SQL*
- 4h (temps estimé) de formation sur OpenClassrooms : *Mettez en place un système de veille informationnelle*
- 12h (temps estimé) de formation sur OpenClassrooms : *Gérez votre temps efficacement*
- 12h (temps estimé) de formation sur OpenClassrooms : *Initiez-vous à la statistique inférentielle*
- 12h (temps estimé) de formation sur OpenClassrooms : *Initiez-vous au langage R pour analyser vos données*
- 12h (temps estimé) de formation sur OpenClassrooms portant : *Utilisez Git et GitHub pour vos projets de développement*
- 2019
 - 1/2 journée de formation sur *Getting the most out of Git*
 - 1/2 journée de formation sur *R/exams: A One-For-All Exams Generator* lors useR 2019 à Toulouse
- 2018
 - Formation sur le deep learning. Formation d'1/2 journée sur le deep learning durant la septièmes rencontres R (Rennes, France) en 2018.
- 2017
 - C.I.B.I.M. (présence) Présence à la conférence annuelle du Centre Interuniversitaire de Biologie Marine à Louvain La Neuve 2017.

Publications

Fullgrabe, Lovina, Philippe Grosjean, Sylvie Gobert, Pierre Lejeune, Michèle Leduc, Guyliann Engels, Patrick Dauby, Pierre Boissery, and Jonathan Richir. 2020. “Zooplankton dynamics in a changing environment: A 13-year survey in the northwestern Mediterranean Sea.” *Marine Environmental Research* 159: 104962. <https://doi.org/https://doi.org/10.1016/j.marenvres.2020.104962>.